

软件工程综合实验要求

海外藏中国文物知识管理与服务平台

北京化工大学

二零二六年四月

实验要求学生综合运用软件工程相关知识，设计并实现一个面向海外藏中国文物的知识管理与服务平台。该平台以知识图谱技术为核心，整合数据爬取、知识建模、信息检索、可视化展示、智能问答等多项技术，涵盖 Web 端、移动端及后台管理系统的完整软件开发实践。

平台共分为五个子系统，如下所述：

- 知识图谱构建子系统：从海外博物馆网站爬取并建模中国文物数据；
- 海外文物知识服务子系统：提供 Web 端数据浏览、查询与可视化服务；
- 知识问答子系统：基于知识图谱实现智能问答功能；
- 掌上博物馆（移动端 App）：面向移动用户的文物展示与交互功能；
- 后台管理子系统：对全平台数据与用户进行统一管理。

1、知识图谱构建子系统

编写程序从海外博物馆网站爬取中国文物信息，经数据清洗、建模与存储，构建结构化的海外文物知识图谱，为知识服务、问答及可视化功能提供数据基础。主要包括以下功能：

（1）数据爬取

爬取至少 3 家指定海外博物馆的全部中国文物信息（博物馆列表见附录），爬取内容至少包括：文物名称、文物图片（原图）、年代、类型、材质、介绍文本、文物详情页 URL。数据按规定格式保存（具体格式见附录），以 UTF-8 编码输出为 CSV 文件，并提交字段说明文档。

技术要求：需处理反爬机制；图片需解析原始地址下载，不得仅保存缩略图；爬取完成后需统计各博物馆文物数量并核验数据完整性。

（2）数据清洗与质量控制

对爬取的原始数据进行清洗处理，主要包括：

- 字段标准化：统一年代格式（如"公元前 206 年"统一表示方式）、文物类型分类等；
- 去重处理：识别并合并同一文物的重复记录；
- 图片有效性验证：检测图片链接是否可正常访问，过滤无效图片。

（3）数据建模

将清洗后的数据转化为三元组形式（主体-谓词-客体），建议参考 CIDOC-CRM 文化遗产领域本体标准进行建模。至少需要定义以下实体类型和关系：

- 实体类型：文物（Artifact）、博物馆（Museum）、朝代（Dynasty）、艺术家（Artist）、地点（Location）等；

- 关系类型：收藏于、创作于、属于朝代、材质为、类型为等。

（4）数据补充

针对基础数据中存在的信息缺失，从外部来源进行定向补充：

- 从百度百科、维基百科等爬取信息，例如书画作家生平、朝代背景、文物介绍等信息；

- 补充数据须与原始数据建立关联，并标注来源与补充日期。

（5）实体对齐与去重

不同博物馆可能收藏同一艺术家的作品或记录相同的历史实体，需进行跨数据源的实体对齐：

- 对艺术家、朝代、地点等共享实体进行识别与合并；
- 建立实体唯一标识符（URI），避免知识图谱中出现重复节点；
- 对齐结果须可追溯，保留原始来源信息。

（6）数据存储

建立双层存储架构，分别满足图查询和业务查询需求：

- 图数据库（Neo4j 或 Virtuoso）：存储全部三元组，支持图查询、关系遍历与 SPARQL 检索；可选发布为链接开放数据（LOD）；

- 关系型数据库（MySQL 或其他）：存储文物详细数据、用户数据及系统业务数据，支持高效的结构化查询。

（7）数据更新与增量爬取

为保持知识图谱的时效性，系统应支持定期数据更新：

- 支持增量爬取，仅爬取上次爬取后新增或更新的文物记录，避免全量重复下载；

- 记录每次爬取的时间、数量与变更详情；
- 对更新的实体数据自动触发三元组重建与图数据库同步。

2、海外文物知识服务子系统

编写 Web 端程序，基于知识图谱构建子系统获取的数据，为用户提供文物数据的浏览、查询、可视化与个性化服务。界面设计可参考克利夫兰艺术博物馆、大英博物馆等国际一流博物馆网站。

（1）数据浏览

提供多维度、多形式的文物浏览体验：

- 列表与卡片视图：支持在列表视图与图片卡片视图之间切换，满足不同用户浏览习惯；
- 多维筛选与排序：支持按文物类型、年代、所属博物馆、材质等多个维度进行组合筛选，支持按名称、年代、更新时间等字段排序；
- 文物详情页：完整展示文物的文本描述、高清图片、三元组属性等信息；图片支持缩放、全屏查看；显示文物在知识图谱中的关联实体；
- 相关文物推荐：在详情页展示相关文物，推荐规则可基于相似主题、同一作者、同一朝代、图像内容相似度等，推荐算法自定；
- 文物对比功能：支持用户选择 2—3 件文物进行横向属性对比，直观展示差异。

（2）数据查询

提供从简单到复杂的多层次查询能力：

- 简单查询：支持按文物名称、博物馆名称、年代等关键字进行全文检索，结果页支持分页与二次筛选；
- 高级查询：支持对文物类型、年代范围、材质、收藏地等多个字段进行组合限定查询，可参考克利夫兰博物馆的高级搜索功能；
- 知识图谱查询：支持用户以自然语言或结构化方式查询实体间的关系，例如"查询某朝代的所有瓷器"或"查询某位艺术家的全部作品"；
- 查询结果导出：支持将查询结果导出为 CSV 或 JSON 格式，便于用户进一步研究使用。

（3）数据可视化

从多个维度对文物知识图谱进行可视化展示：

- 知识图谱关系图：采用力导向图展示文物实体及其关联关系，支持节点

点击展开、悬停显示属性、缩放与拖拽交互，可参考全历史网站、历史人文大数据平台等；

- 文物时间轴：以时间轴形式展示各历史时期的文物分布，支持按朝代或自定义时间段筛选，点击时间节点可跳转至对应文物列表；

- 文物地理分布图：以世界地图形式展示文物现藏博物馆的地理位置，支持点击地图标注查看该博物馆的藏品信息，直观呈现中国文物的海外流散现状

- 统计分析看板：以图表形式展示文物数量、类型占比、朝代分布、博物馆藏量等统计数据，为研究者提供宏观数据视角。

(4) 用户个人信息管理

- 基础功能：用户注册与登录，支持设置用户名、密码、头像等个人信息；
- 浏览记录（选做）：自动记录用户最近浏览的文物，支持一键清除；
- 收藏功能（选做）：支持用户收藏感兴趣的文物，收藏夹支持分组管理；
- 评论与互动（选做）：支持用户对文物发表评论，支持点赞与回复；
- 个性化推荐（选做）：根据用户浏览与收藏记录，在首页推送可能感兴趣的文物。

3、知识问答子系统

本子系统基于知识图谱数据与大语言模型，为用户提供自然语言形式的文物知识问答服务，支持从简单属性查询到复杂关系推理的多层次问答能力。

建议采用“知识图谱+大语言模型”的检索增强生成（RAG）架构：

- 用户输入自然语言问题；
- 系统进行意图识别与实体抽取，将问题转化为图数据库查询语句（SPARQL 或 Cypher）；
- 从知识图谱中检索相关事实与数据；
- 将检索结果作为上下文传入大语言模型，生成自然流畅的回答；
- 返回答案并标注数据来源。

该架构既保证了答案的事实准确性（来自知识图谱），又具备良好的语言表达能力（来自大语言模型），有效避免大模型幻觉问题。

(1) 简单问答

支持单实体单属性的问答，至少覆盖以下 10 类问题：

- 文物收藏地：该文物现藏于哪家博物馆？
- 文物年代：该文物属于哪个历史时期？
- 文物材质：该文物由什么材料制成？
- 文物类型：该文物属于哪种器物类别？
- 文物介绍：请介绍一下这件文物。
- 书画作者：该书画作品的作者是谁？针对书画类文物。
- 作者生平：该作者的生平经历是怎样的？针对书画类文物。
- 同一作者作品：该作者还有哪些作品被海外博物馆收藏？
- 同一朝代文物：某朝代有哪些代表性文物？
- 文物尺寸与规格：该文物的尺寸和重量是多少？
- 相关文物推荐：与该文物风格或主题相似的文物有哪些？

技术要求：对于知识图谱中不存在的问题，应明确告知用户“暂无相关数据”，而非生成不实答案。

（2）答案溯源与可信度展示

为增强问答系统的可信度，每条回答须附带数据来源说明：

- 标注答案来源（如“数据来源：克利夫兰艺术博物馆”）；
- 提供指向原始数据详情页的链接；
- 对于由大语言模型生成的补充性描述，须与知识图谱事实性内容明确区分标注。

（3）多轮对话（选做）

支持基于上下文的连续追问，提升问答交互的自然性：

- 系统能够理解代词指代，例如用户先问“青花瓷是什么？”后问“它主要产于哪个朝代？”，系统能正确理解“它”指代青花瓷；
- 保留最近 5 轮对话上下文用于意图理解；
- 支持用户主动切换话题，系统能识别并重置上下文。

（4）复杂问答（选做）

支持需要多步推理或跨实体关联的复杂问题，主要包括：

- 多跳推理问答：例如“收藏青铜器最多的博物馆是哪家？该博物馆在哪个

城市？ ”

- 比较类问答：例如“唐代和宋代的瓷器在风格上有何不同？”
- 统计类问答：例如“大都会博物馆共收藏了多少件中国文物？”
- 路径查询：例如“某件文物与某位历史人物之间有什么关联？”

技术建议：可基于知识图谱的多跳查询（如 SPARQL 路径查询）结合大语言模型进行推理链生成。

（5）问答质量反馈机制（选做）

建立用户反馈，持续优化问答质量：

- 每条回答下方提供“有帮助”与“不准确”两个反馈按钮；
- 对于用户标记为不准确的回答，记录至问题日志供人工审核；
- 统计高频未能正确回答问题类型，为知识图谱补充与模型优化提供依据。

（6）闲聊与文化导览（选做）

支持与用户进行文物文化相关主题的自由对话：

- 能够介绍中国各历史朝代的文化背景与艺术特色；
- 能够讲解中国传统工艺（如陶瓷烧制、书画技法等）的基础知识；
- 支持根据用户兴趣推荐相关文物或拓展阅读内容；
- 对于超出文物文化领域的话题，礼貌告知用户系统专注范围。

4、掌上博物馆

基于 HarmonyOS 开发手机端 App，建议使用 ArkTS 语言与 ArkUI 框架进行开发。从知识图谱数据中选取单类文物作为展示主题，例如瓷器、玉器、青铜器或中国画等，为用户提供沉浸式的文物浏览与互动体验。可参考故宫博物院 App（<https://www.dpm.org.cn/Creative.html#app>）。

（1）文物浏览

提供丰富的文物展示与浏览体验：

- 首页展示：以卡片或瀑布流形式展示文物列表，支持按热度、年代、类型等排序；
- 文物详情：展示文物高清图片（支持手势缩放与多图切换）、基本属性、详细介绍文本；

- 音视频讲解：若提供讲解音频或视频，支持在文物详情页内嵌播放，支持倍速与进度控制；

- 简单搜索：支持按文物名称、朝代、关键字进行全文搜索，搜索结果支持分类展示。

（2）语音导览

利用 HarmonyOS 的语音能力，提供解放双手的文物导览体验：

- 为每件文物提供标准普通话语音讲解，支持在文物详情页一键播放；
- 支持语音搜索：用户可通过语音输入关键字查找文物；
- 支持语音问答：用户可对着手机说出关于文物的问题，系统调用知识问答子系统返回语音答案。

（3）用户交互

丰富的用户参与以及内容共创功能：

- 点赞与收藏：支持用户对文物点赞和收藏，收藏夹支持分组管理；
- 留言评论：支持用户对文物发表文字评论，支持点赞与回复他人评论；评论须经内容审核后显示；
- 用户上传照片：用户可上传自己拍摄的文物相关照片（如参观博物馆时拍摄），照片须经审核后公开展示；支持为照片添加拍摄地点与简短说明；
- 用户上传讲解（选做）：支持用户录制或上传针对某件文物的音频讲解，经审核后可供其他用户收听；
- 用户上传视频（选做）：支持用户上传与文物相关的短视频，经审核后展示。

（4）以图搜图

支持基于图像特征的文物检索功能：

- 图片上传搜索：用户从相册选择图片上传，系统提取图像特征后在文物数据库中检索相似文物；
- 实时拍照搜索：用户直接调用摄像头拍摄文物或相关图片，即时返回匹配结果；
- 搜索结果展示：按相似度排序展示匹配文物列表，显示相似度分值与文物基本信息；

- 技术建议：可使用预训练的图像特征提取模型（如 ResNet、ViT 等）提取文物图像特征向量，存入向量数据库，搜索时计算余弦相似度进行检索。

（5）用户个人信息管理

- 注册与登录：支持手机号、邮箱注册，支持密码登录；可选支持华为账号一键登录；

- 个人主页：展示用户的收藏、点赞、上传内容、浏览历史等个人数据；

- 隐私设置：用户可控制个人信息的可见范围；

- 用户系统可与海外文物知识服务子系统共用，或单独建立，需在设计文档中说明选择理由。

（6）用户动态（选做）

- 支持用户发布包含文字与图片的动态，分享文物或博物馆相关内容；

- 动态可关联到具体文物或博物馆，点击可跳转至对应详情页；

- 其他用户可对动态点赞与评论；

- 支持关注其他用户，首页展示关注用户的最新动态；

- 所有动态内容须经过内容审核方可公开展示。

（7）消息通知（选做）

- 利用 HarmonyOS 通知能力，向用户推送个性化消息；

- 当用户上传的照片或评论通过审核后，发送通知；

- 当关注的用户发布新动态时，发送通知；

- 定期推送"文物今日推荐"，引导用户探索新内容；

- 用户可在设置中自定义通知类型与频率注意。

可自行设计增加更多功能。可参考 <https://www.dpm.org.cn/Creative.html#app>。

5、后台管理子系统

编写 Web 端后台管理程序，对平台全部数据、用户、内容与系统运行状态进行统一管理，确保平台安全、稳定、高效运行。后台系统须设置独立的管理员账号体系，与前台用户账号分离。

（1）角色与权限管理

建立基于角色的访问控制机制，至少定义以下三类角色：

- 超级管理员：拥有全部操作权限，包括创建和管理其他管理员账号、系统配置等；

- 内容审核员：仅拥有内容审核相关权限，无法操作用户数据与系统配置；

- 数据管理员：拥有文物数据的增删改查权限，无法操作用户账号与系统日志。

支持自定义角色，可灵活分配各模块的查看、编辑、删除等细粒度权限；所有权限变更须记录操作日志。

(2) 用户管理

对全平台所有用户进行统一管理，涵盖后台管理员、知识服务子系统用户、掌上博物馆用户：

- 用户信息管理：支持对用户基础信息的增删改查，支持按用户名、注册时间、用户来源等条件筛选，支持批量操作；

- 用户状态管理：支持启用、禁用用户账号；对违规用户支持细粒度权限限制，如仅禁止评论、禁止上传图片等，而非直接封禁账号；

- 用户行为记录：可查看特定用户的操作历史，包括发布内容、评论、上传记录等，便于违规行为溯源；

- 违规处理记录（选做）：记录每次对用户的处罚操作，包括处罚原因、操作人、处罚时间与解除时间，支持申诉处理流程。

(3) 内容审核

建立"自动审核+人工审核"的双重内容审核机制，确保平台内容合规：

自动审核：

- 文本审核：维护敏感词库，支持管理员在线增删敏感词；用户提交内容时自动检测，命中敏感词则拦截并提示用户修改；

- 图片审核：调用图像识别接口对用户上传图片进行违规内容检测，审核不通过的图片自动屏蔽并记录；

- 自动审核结果可配置：管理员可设置各类内容的审核策略，如"低风险自动通过、高风险转人工审核"。

人工审核：

- 待审核队列：展示所有待人工审核的内容（文本、图片、音视频），支

持按内容类型、提交时间筛选；

- 审核操作：审核员可对每条内容执行通过、拒绝、标记复审等操作，拒绝时须填写拒绝原因；

- 批量审核：支持对同类内容进行批量通过或拒绝操作，提升审核效率；

- 审核统计：展示每日审核量、通过率、拒绝率等统计数据，支持按审核员维度统计工作量。

（4）数据管理

对全平台所有业务数据进行统一管理：

- 文物数据管理：对知识图谱中的文物数据进行增删改查，支持批量导入（CSV/JSON 格式）与导出，支持图片的批量上传与替换；

- 知识图谱管理：支持对三元组数据的在线编辑，包括添加、修改、删除实体与关系，修改后可触发图数据库同步更新；

- 用户生成内容管理：管理用户上传的评论、图片、音视频等内容，支持按来源子系统、内容类型、审核状态筛选；

- 数据一致性检查（选做）：定期检测关系型数据库与图数据库之间的数据一致性，对发现的不一致记录生成报告并支持手动修复。

（5）数据备份与恢复

保障平台数据安全，防止数据意外丢失：

- 手动备份：管理员可随时触发全量备份或指定数据库的备份操作；

- 定时自动备份：支持配置定时备份任务，如每日凌晨自动全量备份，备份文件自动加密存储；

- 备份记录管理：展示所有备份记录列表，包括备份时间、备份类型、文件大小、操作人等信息；支持下载备份文件；

- 数据恢复：支持从任意备份记录点恢复数据库，恢复前须经超级管理员二次确认；恢复操作须记录详细日志；

- 备份存储管理：支持设置备份保留策略（如保留最近 30 天的备份），自动清理过期备份文件。

（6）日志管理

建立完善的操作日志体系，支持审计与问题排查：

- 操作日志：记录所有管理员的后台操作，包括操作人、操作时间、操作类型、操作对象与操作前后的数据变化；

- 系统日志：记录系统运行中的异常事件、接口错误、定时任务执行情况等；

- 安全日志：记录登录行为（包括失败登录）、权限变更、敏感数据访问等安全相关事件

- 日志查询：支持按时间范围、操作人、操作类型、关键字等多维度检索日志；

- 日志导出：支持将查询结果导出为 CSV 或 Excel 格式，便于合规审计。

（7）系统监控看板

实时展示平台运行状态，帮助管理员及时发现并处理异常：

- 实时数据统计：展示当前在线用户数、今日新增用户数、今日内容提交量、审核队列积压量等关键指标；

- 访问量统计：以折线图展示各子系统的日/周/月访问量趋势；

- 数据增长统计：展示文物数据量、用户数量、内容数量等随时间的增长趋势，为运营决策提供数据支撑；

- 异常告警（选做）：当系统出现接口响应超时、数据库连接失败、磁盘空间不足等异常时，在看板显示告警信息并支持邮件或短信通知管理员。

（8）系统配置管理（选做）

支持在线修改系统运行参数，无需重启服务：

- 敏感词库管理：在线增删改查敏感词，支持批量导入；

- 审核策略配置：配置各类内容的自动审核阈值与人工审核触发条件；

- 系统公告管理：发布、编辑、下线面向前台用户的系统公告或维护通知；

- 功能开关：支持对各子系统的特定功能进行在线开启或关闭，便于灰度发布与紧急处置。

附录 1：参考资料

一、知识图谱构建相关

(1) CIDOC-CRM 文化遗产领域本体标准

CIDOC-CRM 是文化遗产领域信息整合的理论与实践工具，已被国际标准化组织采纳为 ISO 21127:2023 标准，是文化遗产信息受控交换的国际标准。该标准在中国也有等效采标版本 GB/T 37965-2019《信息与文献 文化遗产信息交换参考本体》，可在国家标准查询系统中获取。

- 官方文档：

https://cidoc-crm.org/html/cidoc_crm_v7.1.1_with_translations.html

- 官网主页：<https://cidoc-crm.org/>

- 维基百科介绍：

https://en.wikipedia.org/wiki/CIDOC_Conceptual_Reference_Model

(2) 知识图谱建模工具

① Protégé（斯坦福大学，免费开源，推荐）

Protégé 是斯坦福大学开发的免费开源本体编辑器，被全球研究人员、组织和政府机构广泛用于构建和管理本体。提供本地桌面版（Protégé Desktop）和在线协作版（WebProtégé）两种形式，完整支持 W3C 的 OWL 2 标准。Protégé 适合在建模阶段设计和可视化文物知识图谱的类、属性和关系结构，是学术界最常用的本体开发工具。

官网：<https://protege.stanford.edu/>

GitHub：<https://github.com/protegeproject/protege>

适用场景：本体设计、OWL/RDF 结构可视化、一致性验证

② RMLMapper / Morph-KGC（数据到 RDF 映射，推荐）

RMLMapper 是 RML（RDF Mapping Language）规范的参考实现，支持将 CSV、JSON、XML、关系型数据库等多种格式的数据转化为高质量的链接数据（RDF）。Morph-KGC 是一个更强大的 RML 引擎，支持大规模数据，可从命令行运行或作为 Python 库调用。Fairplus 对于本课程设计而言，可直接用 RML 规则将爬取的 CSV 格式文物数据映射为三元组，无需手动编写转换代码。

RMLMapper GitHub: <https://github.com/RMLio/rmlmapper-java>

Morph-KGC GitHub: <https://github.com/morph-kgc/morph-kgc>

YARRRML (RML 的可读性更强的语法): <https://rml.io/yarrrml/>

适用场景: 将爬取的 CSV/JSON 文物数据批量转化为 RDF 三元组

③ RDFLib (Python 库, 轻量推荐)

纯 Python 实现的 RDF 处理库, 支持三元组的读写、SPARQL 查询、格式转换等操作, 无需额外安装数据库或图形界面, 适合在代码中直接操作和生成三元组数据。

官方文档: <https://rdflib.readthedocs.io/en/stable/>

GitHub: <https://github.com/RDFLib/rdflib>

适用场景: 编程方式生成和操作三元组, 与 Python 爬虫代码无缝集成

④ Karma

USC ISI 开发的半自动数据建模工具, 支持将结构化数据映射到本体。

项目地址: <https://github.com/usc-isi-i2/Web-Karma>

说明: 网络中文资料较少, 建议直接参考项目 Wiki 文档

(3) Neo4j 图数据库

Neo4j 支持从非结构化数据构建知识图谱的完整流水线, 包括数据加载、文本分块、实体与关系抽取、知识图谱写入与实体解析等组件, 并可与大语言模型集成构建 GraphRAG 应用。 [Neo4j](#)

- 官方文档: <https://neo4j.com/docs/>

- 知识图谱构建指南:

<https://neo4j.com/developer/genai-ecosystem/importing-graph-from-unstructured-data/>

- GitHub 仓库: <https://github.com/neo4j/neo4j>

(4) Virtuoso 开源图数据库

支持 SPARQL 查询与链接开放数据 (LOD) 发布, 适合大规模三元组存储。

- GitHub 仓库: <https://github.com/openlink/virtuoso-opensource>

- 官方网站: <https://virtuoso.openlinksw.com/>

(5) LangChain 知识图谱与 RAG 开发框架

LangChain 提供了完整的检索增强生成（RAG）支持，可将外部知识库与大语言模型结合，解决模型知识截止和幻觉问题，建议用于知识问答子系统的开发。

- 官方文档: <https://docs.langchain.com/>
- RAG 入门指南: <https://www.langchain.com/retrieval>

二、数据爬取相关

（6）Scrapy 网络爬虫框架

Python 生态中最主流的爬虫框架，支持异步爬取、中间件扩展与数据管道，适合大规模博物馆数据爬取。

- 官方文档: <https://docs.scrapy.org/en/latest/>
- GitHub 仓库: <https://github.com/scrapy/scrapy>

（7）Selenium / Playwright 动态页面爬取

部分博物馆网站采用 JavaScript 动态渲染，需使用浏览器自动化工具爬取。

- Selenium 官方文档: <https://www.selenium.dev/documentation/>
- Playwright 官方文档: <https://playwright.dev/python/docs/intro>

（8）Pandas 数据处理库

用于 CSV 格式数据的读写、清洗与字段处理，避免编码格式错误。

- 官方文档: <https://pandas.pydata.org/docs/>

三、以图搜图相关

（9）FAISS 向量相似搜索库（Meta AI）

FAISS 是一个用于高效相似性搜索和密集向量聚类的库，包含可在任意规模向量集合中搜索的算法，甚至支持超出内存容量的数据集，由 Meta AI 研究院开发，采用 MIT 协议开源。 [GitHub](#)

- 官方 GitHub: <https://github.com/facebookresearch/faiss>
- 使用教程: <https://www.pinecone.io/learn/series/faiss/faiss-tutorial/>

（10）CLIP 图像特征提取模型（OpenAI）

CLIP 是 OpenAI 开发的多模态视觉-语言模型，将图像和文本映射到同一语义空间，可用于以图搜图或以文搜图，结合 FAISS 可构建高效的图像相似性检索引擎。 [Medium](#)

- HuggingFace 模型页面: <https://huggingface.co/openai/clip-vit-base-patch32>
- 以图搜图教程 (CLIP + FAISS) :
<https://blog.roboflow.com/clip-image-search-faiss/>

四、Web 前端与可视化相关

(11) D3.js 数据可视化库

用于知识图谱力导向图、时间轴等复杂可视化的实现。

- 官方文档: <https://d3js.org/>
- 示例库: <https://observablehq.com/@d3/gallery>

(12) ECharts 可视化库 (Apache)

百度开源、Apache 基金会维护的可视化库, 提供关系图、时间轴等组件, 中文文档完善, 适合国内开发者使用。

- 官方文档: <https://echarts.apache.org/zh/index.html>
- 关系图示例: <https://echarts.apache.org/examples/zh/index.html#chart-type-graph>

(13) KnightLab Timeline JS

开源时间轴工具, 可将 Google 表格数据转化为交互式时间轴, 适合文物历史时间轴功能。

- 官网: <https://timeline.knightlab.com/>

五、参考博物馆与平台

(14) 克利夫兰艺术博物馆 (含高级搜索与 Open Access API)

- 搜索界面: <https://www.clevelandart.org/art/collection/search>
- Open Access 数据集: <https://openaccess-api.clevelandart.org/>

(15) 大都会艺术博物馆 Open Access API

提供约 48 万件文物的结构化数据, 支持 JSON 格式直接调用, 可作为爬取数据的补充来源。

- API 文档: <https://metmuseum.github.io/>

(16) 全历史知识图谱平台

国内优秀的历史人文知识图谱可视化案例，可参考其关系图谱与时间轴的交互设计。

- 网站：<https://www.allhistory.com/>

(17) 故宫博物院 App

国内博物馆移动端 App 的优秀参考案例，可参考掌上博物馆的功能设计与交互方式。

- 官网：<https://www.dpm.org.cn/Creative.html#app>

附录 2：数据爬取格式及要求

(1) 数据格式要求

所有爬取数据须遵循以下格式规范：

- 编码格式：统一使用 UTF-8 编码保存，避免中文乱码；
- 文件格式：保存为 CSV 格式，建议使用 Python 的 csv 或 pandas 库进行读写，防止出现分隔符冲突、换行符异常等格式错误；
- 文件命名：按博物馆命名，例如 cleveland_museum.csv、metropolitan_museum.csv；
- 图片存储：图片文件按博物馆分文件夹存放，文件名与 CSV 中的文物 ID 一一对应，例如 images/cleveland/obj_12345.jpg；
- 各组须自行验证导出的 CSV 文件可在 Excel 或 pandas 中正常打开，确认无乱码、无格式错误后方可提交。

(2) 数据字段要求

每条文物记录至少包含以下字段（部分字段如博物馆网站未提供可标注为空）：

字段名（英文）	中文说明	是否必填	备注
object_id	文物唯一标识符	必填	使用博物馆原始 ID 或自行生成
title	文物名称	必填	优先保留英文原名，有中文译名则补充
period	年代/时期	必填	如“Tang Dynasty”或“618 - 907 AD”
type	文物类型	必填	如 Painting、Ceramics、Bronze 等
material	材质	建议填写	如 Silk、Bronze、Jade 等
description	文物介绍	必填	爬取网站提供的原始描述文本
dimensions	尺寸	建议填写	如“H. 30 cm × W. 20 cm”
museum	所属博物馆	必填	填写博物馆完整英文名称
location	博物馆所在地	必填	城市、国家
detail_url	文物详情页 URL	必填	文物在博物馆网站上的原始页面链

字段名（英文）	中文说明	是否必填	备注
			接
image_url	图片原始下载链接	必填	须为原图地址，而非缩略图
image_path	本地图片存储路径	必填	图片下载后的相对路径
credit_line	版权/来源说明	建议填写	博物馆提供的版权声明
accession_number	藏品编号	建议填写	博物馆馆藏编号
crawl_date	爬取日期	必填	格式：YYYY-MM-DD

注意事项：

- 图片爬取须注意解析原图地址，部分网站（如大都会博物馆）需要通过 API 获取高清原图链接，不可仅保存页面展示的缩略图；
- 对于缺失字段，用空字符串填充，不可省略该列；
- 文物介绍若为英文，建议同时保留原文，后续可通过翻译 API 补充中文描述。

（3）数据量要求

- 每组须爬取指定的 3 家博物馆，筛选其中的中国文物；
- 最终提交数据总量不少于 5000 件文物的有效记录（含图片）。

（4）数据质量验收标准

提交前须自行检查以下内容，并在说明文档中附上检查结果：

- 必填字段完整率：object_id、title、detail_url、image_url、crawl_date 五个必填字段不得有空值；
- 图片有效性：随机抽查 20 条记录，验证图片文件可正常打开，且为原图而非缩略图；
- 编码正确性：读取 CSV 后打印前 5 行，确认中文字符无乱码；
- URL 有效性：随机抽查 10 条 detail_url，验证链接可正常访问。

（5）说明文档要求

每组须提交一份数据说明文档（Markdown 或 Word 格式），内容包括：

- 字段说明表：列出所有字段的英文名、中文含义、数据类型与示例值，

例如：

英文字段名	中文说明	数据类型	示例
period	文物年代	字符串	Tang Dynasty
crawl_date	爬取日期	日期	2024-03-15

- 爬取说明：说明各博物馆爬取时遇到的技术难点及解决方案，如反爬处理方式、原图地址解析方法等

- 数据统计：各博物馆爬取记录数、图片下载成功率、字段缺失情况统计
- 数据质量自查报告：按照第（4）条验收标准的自查结果

附录 3：数据爬取网站

每团需爬取 3 家海外博物馆。为平衡各组爬取数量，请按照下表爬取。如需调换，需要两组组长同意后，上报助教老师

表 1 网站分配

团号	爬取博物馆序号（对应见下表）		
1 团	1	6	11
2 团	2	7	12
3 团	3	8	13
4 团	4	9	14
5 团	5	10	15

表 2 海外博物馆名称、网址和中国文物数量

序号	博物馆名	网址
1	克利夫兰	https://www.clevelandart.org/art/collection/search
2	大都会	https://www.metmuseum.org/art/collection
3	史密斯	https://www.si.edu/openaccess
4	弗利尔美术馆	https://www.freersackler.si.edu/collections/ https://asia.si.edu/collection-area/chinese-art/
5	普林斯顿大学艺术博物馆	https://artmuseum.princeton.edu/search/collections
6	纳尔逊-阿特金斯艺术博物馆	https://art.nelson-atkins.org/collections
7	旧金山亚洲艺术博物馆	http://searchcollection.asianart.org/view/objects/asi_mages/23140?t:state:flow=925e5439-97d7-4a9b-9733-62cdb565a1d9
8	波士顿美术馆	https://www.mfa.org/collections/search
9	明尼阿波利斯艺术博物馆	https://collections.artsimia.org/
10	芝加哥艺术博物馆	https://www.artic.edu/collection?place_ids=China
11	宾夕法尼亚大学考古与人类学博物馆	https://www.penn.museum/
12	费城艺术博物馆	https://www.philamuseum.org/collections/search.ht

		<u>ml</u>
13	哈佛大学	<u>https://harvardartmuseums.org/collections?q=chinese</u>
14	美国自然历史博物馆	<u>https://anthro.amnh.org/collections</u>
15	布鲁克林艺术博物馆	<u>https://www.brooklynmuseum.org/opencollection/collections</u>

注：国外博物馆一般可在博物馆网站文物搜索栏中使用“chinese”，“china”等关键字进行筛选，还可在网站上提供的 location 等字段进行筛选，以得到中国文物。